МИНОБРНАУКИ РОССИИ

САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ

ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)

Кафедра МО ЭВМ

ОТЧЕТ

по лабораторной работе №5

по дисциплине «Построение и анализ алгоритмов»

ТЕМА: АЛГОРИТМ АХО-КАРАСИК.

Студент гр. 7304 Сергеев И.Д.

Преподаватель Филатов Ар.Ю.

Санкт-Петербург

2019

Цель работы:

Исследовать алгоритм Ахо-Корасик, который реализует поиск множетсва подстрок из словаря в данной строке.

Задача:

---

1) Разработайте программу, решающую задачу точного поиска набора образцов.

2) Используя реализацию точного множественного поиска, решить задачу поиска для одного образца с джокером.

Основные теоретические положения:

Бор (англ. trie, луч, нагруженное дерево) — структура данных для хранения набора строк, представляющая из себя подвешенное дерево с символами на рёбрах. Строки получаются последовательной записью всех символов, хранящихся на рёбрах между корнем бора и терминальной вершиной. Размер бора линейно зависит от суммы длин всех строк, а поиск в бору занимает время, пропорциональное длине образца.

Детерминированный конечный автомат (ДКА) (англ. deterministic finite automaton (DFA)) — набор из пяти элементов $\langle \Sigma, Q, s \in Q, T \subset Q, \delta: Q \times \Sigma \to Q \rangle$, где Σ — алфавит (англ. alphabet), Q — множество состояний (англ. finite set of states), s — начальное (стартовое) состояние (англ. start state), T — множество допускающих состояний (англ. set of accept states), δ — функция переходов (англ. transition function).

Ход работы:

1. **Реализован алгоритм Ахо-Карасик**
    a. Была реализована структура вершины в боре. Next_vrtx соседние вершины, pat_num – номер строки, suff_link – суффиксная ссылка, auto_move – массив переходов автомата, par – предок вершины, flag – флаг, который показывает удовлятворяет ли вершина шаблону или нет, number – порядковый номер введенной строки.

```
struct bohr_vrtx{
  int next_vrtx[k],pat_num,suff_link,auto_move[k],par,suff_flink;
  bool flag;
```

```
  int number;
  char symb;
};
bohr_vrtx make_bohr_vrtx(int p,char c){
  bohr_vrtx v;
  memset(v.next_vrtx, 255, sizeof(v.next_vrtx));
  memset(v.auto_move, 255, sizeof(v.auto_move));
  v.flag=false;
  v.suff_link=-1;
  v.par=p;
  v.symb=c;
  v.suff_flink=-1;
  return v;
}
```

b. Была реализована функция, добавляющая строку в бор. Сначала мы в нулевой корневой вершине. Далее идем по доступным вершинам, если нельзя то создаем вершину и переход и переходим по ней.

```
void add_string_to_bohr(string& s,int n){
  int num=0;
  for (int i=0; i<s.length(); i++){
    char ch = sym.find(s[i]);
    if (bohr[num].next_vrtx[ch]==-1){
      bohr.push_back(make_bohr_vrtx(num,ch));
      bohr[num].next_vrtx[ch]=bohr.size()-1;
      }
    num=bohr[num].next_vrtx[ch];
  }
  bohr[num].flag=true;
  bohr[num].number = n;
  pattern.push_back(s);
  bohr[num].pat_num=pattern.size()-1;
}
```

c. Были реализованы 2 функции, которые строят по данному бору конечный детерминированный автомат, который строится по ходу работы алгоритма. Получаем суффиксальную ссылку для данной вершины. Если она не определена (=-1), то сначала проверяем не корень ли это или ее предок корень, тогда суфф. Ссылка будет 0, иначе переходим на предка и пытаемся пройти

по данному символу, если нельзя повторяем. В функции get_auto_move осуществляется переход, который выдает следующее состояние.

```
int get_auto_move(int v, char ch);
int get_suff_link(int v){
  if (bohr[v].suff_link==-1)
    if (v==0||bohr[v].par==0)
      bohr[v].suff_link=0;
    else
      bohr[v].suff_link=get_auto_move(get_suff_link(bohr[v].par),
bohr[v].symb);
  return bohr[v].suff_link;
}
int get_auto_move(int v, char ch){
  if (bohr[v].auto_move[ch]==-1)
    if (bohr[v].next_vrtx[ch]!=-1)
      bohr[v].auto_move[ch]=bohr[v].next_vrtx[ch];
    else
      if (v==0)
        bohr[v].auto_move[ch]=0;
      else
        bohr[v].auto_move[ch]=get_auto_move(get_suff_link(v), ch);
  return bohr[v].auto_move[ch];
}
int get_suff_flink(int v){
  if (bohr[v].suff_flink==-1){
    int u=get_suff_link(v);
    if (u==0)
      bohr[v].suff_flink=0;
    else
      bohr[v].suff_flink=(bohr[u].flag)?u:get_suff_flink(u);
  }
  return bohr[v].suff_flink;
}
```

2. **Реализована задача множественного поиска**
   - **a.** Задача имеет некоторые отличия от предыдущей.
   - **b.** Паттерн-строка разделяется на строки джокерами, запоминаем их индексы.

c. Создаем массив нулей размера текста
d. Для каждого вхождения паттерна инкрементируем i – j + 1 позицию в массиве, где i – индекс вхождения, j – позиция данного паттерна в исходно паттерне.
e. В тех позициях массива, где значение совпадает с количеством паттернов, присутствует совпадение с исходным.

Результат:

1)

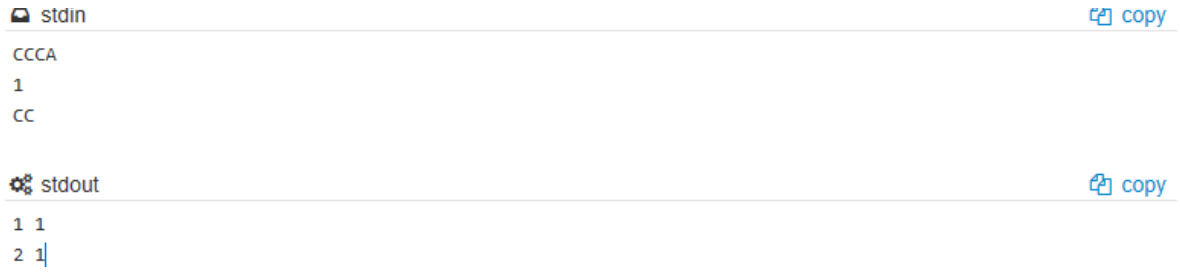

2)

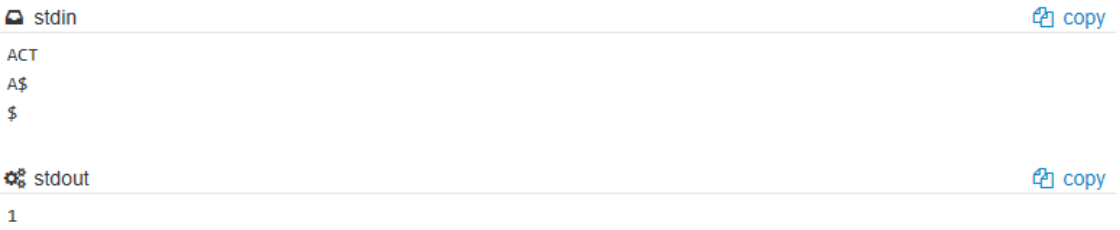

Вывод:

Таким образом, в ходе данной лабораторной работы был реализован алгоритм Ахо-Карасика на языке c++. Данный алгоритм точный поиск набора образцов в строке. Используются такие понятия, как бор, конечный автомат, суффиксальные ссылки. Также алгоритм был использован для поиска в строке паттерна, содержащего джокер.

В ходе данной работы столкнулся с проблемой построения конечного автомата и переходам по суффиксальным ссылкам, а также с проблемой реализация поиска строки с джокером.